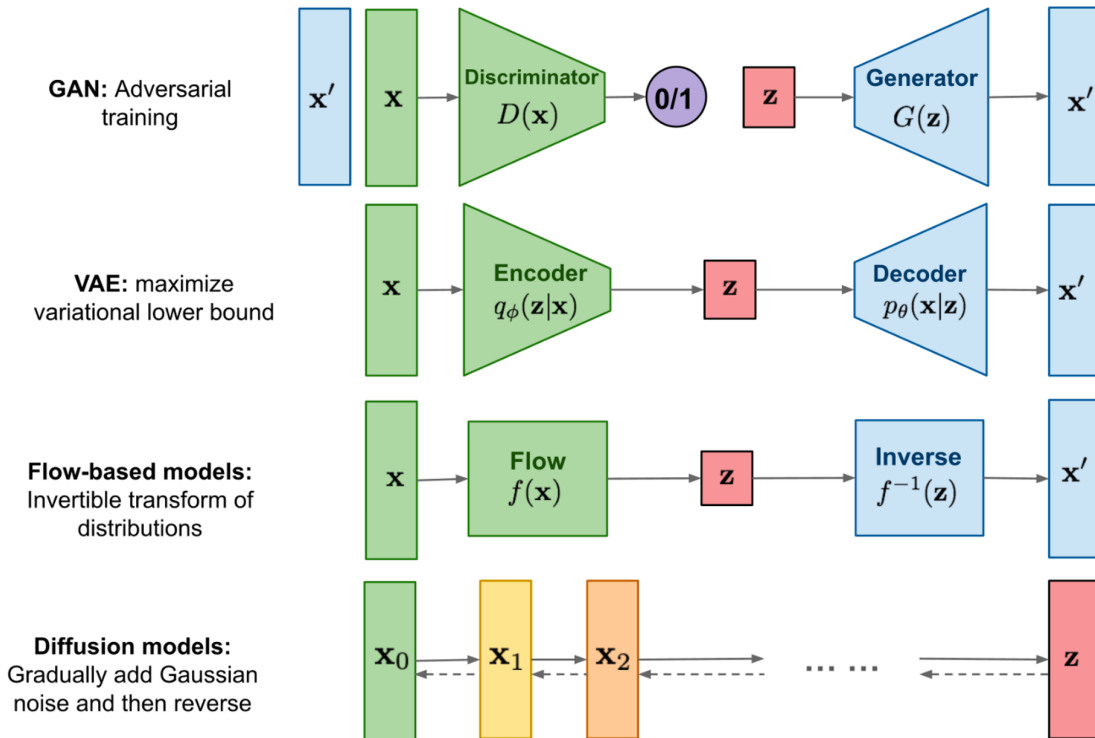


Generative Adv



[GAN](#)

[VAE](#)

[Flow-base model](#)

[Diffusion](#)

GAN

GAN(적대적 생성 신경망)은 인공지능 기술 중 하나로, 실제와 유사한 데이터를 생성할 수 있는 모델이다.

이는 2 개의 서로 경쟁하는 네트워크, 생성자(Generator)와 판별자(Discriminator)를 사용하여 학습한다.

생성자는 진짜와 같은 데이터를 생성하려고 시도하고, 판별자는 입력 데이터가 실제 데이터인지 생성자가 생성한 가짜 데이터인지를 구분하려고 한다

- 구조
 - 생성자 (Generator): 랜덤 노이즈로부터 가짜 데이터를 생성

- 판별자 (Discriminator): 입력된 데이터가 진짜인지 가짜인지 판별

- 학습 과정

1. 생성자는 무작위로 노이즈를 받아 가짜 데이터를 생성한다.
2. 판별자는 실제 데이터와 생성자가 만든 가짜 데이터를 받아 실제인지 가짜인지를 판별한다.
3. 학습 목표: 생성자는 판별자를 속여 가짜 데이터를 실제처럼 보이게 만들려고 하고, 판별자는 실제와 가짜를 정확하게 구별하려고 한다. 이 과정에서 생성자와 판별자는 서로를 개선하며 경쟁적으로 학습한다.

- GAN의 목적 함수

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$

- G : 생성자 함수

- 노이즈 분포 $p_z(z)$ 에서 샘플링한 z 를 입력으로 받아 데이터 공간의 샘플을 생성한다.

- D : 판별자 함수

- 실제 데이터 x 또는 생성된 데이터 $G(z)$ 를 입력으로 받아 실제 데이터일 확률을 추정한다.

- p_{data} : 실제 데이터 분포

- p_z : 생성자의 입력으로 사용되는 노이즈 분포

→ 판별자 D 가 실제 데이터와 생성된 데이터를 정확하게 구별하려고 할 때 최대화되며, 생성자 G 는 판별자 D 를 속여 생성된 데이터가 실제 데이터처럼 보이게 하려고 할 때 최소화된다. 이러한 경쟁을 통해 생성자는 점점 더 실제와 유사한 데이터를 생성하게 된다.

VAE

VAE(변분 오토인코더) : 딥러닝과 베이지안 추론을 결합한 생성 모델

VAE는 데이터의 복잡한 확률 분포를 학습하여 새로운 데이터를 생성할 수 있다. 이 과정에서 VAE는 입력 데이터를 잠재 공간(latent space)의 저차원 표현으로 압축(인코딩)한 뒤, 이를 다시 원본 데이터 공간으로 복원(디코딩)한다. VAE의 핵심은 인코더와 디코더 사이의 잠재 공간을 확률적으로 모델링하는 것이다.

- 구조
 - 인코더 (Encoder)
 - 입력 데이터 x 를 받아 잠재 변수 z 의 조건부 분포 $q_\phi(z|x)$ 의 파라미터를 출력한다.
 - ϕ : 인코더의 파라미터
 - 디코더 (Decoder)
 - 잠재 변수 z 를 받아 원본 데이터 x 를 재구성하는 데이터의 조건부 분포 $p_\theta(x|z)$ 의 파라미터를 출력한다.
 - θ : 디코더의 파라미터

- VAE의 목적 함수

VAE의 학습 목표: 데이터의 로그 우도 $\log p_\theta(x)$ 를 최대화하는 것

- 하지만 직접 계산이 불가능하기 때문에, 대신 Evidence Lower BOund (ELBO)를 최대화한다.

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E} q_\phi(z|x) [\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) || p(z))$$

- 첫 번째 항: 재구성 로그 우도
- 두 번째 항: $q_\phi(z|x)$ 와 사전 분포 $p(z)$ 사이의 Kullback-Leibler (KL) 발산
 - 이 발산은 잠재 변수의 사전 분포와 인코더가 추정된 분포 사이의 차이를 측정한다.

- 핵심

- 재구성 손실
 - 입력 데이터와 재구성된 데이터 사이의 차이를 최소화한다
- 정규화 손실

- 인코더가 출력하는 잠재 변수의 분포가 사전 분포 $p(z)$ 에 가까워지도록 한다.
- 일반적으로 $p(z)$ 는 표준 정규 분포를 사용한다.

→ VAE는 이 두 가지 손실을 동시에 최소화함으로써, 입력 데이터를 잘 재구성하면서도 잠재 공간을 의미 있게 구성할 수 있다. 이를 통해 VAE는 새로운 데이터를 생성하거나 데이터의 특성을 이해하는 데 사용될 수 있다.

Flow-base model

Flow-based 모델 : 데이터의 복잡한 확률 분포를 학습하고 새로운 데이터를 생성할 수 있는 딥러닝 기반의 생성 모델

이 모델은 데이터와 잠재 공간 사이의 변환을 가역적인 함수(즉, 역함수가 존재하는 함수)를 사용하여 정의한다. 이러한 특성 때문에 Flow-based 모델은 데이터의 정확한 확률 밀도를 계산할 수 있으며, 이를 통해 고품질의 데이터 생성이 가능하다.

- 핵심
 - 가역성(Reversibility)
 - 데이터와 잠재 공간 사이의 변환을 가역적인 함수로 모델링하는 것
 - 이를 통해 데이터의 손실 없이 잠재 공간으로의 매핑과 그 역매핑이 가능하다.
 - 정규화 흐름(Normalizing Flows)
 - 복잡한 확률 분포를 간단한 분포(예: 표준 정규 분포)에서 시작하여 일련의 가역적 변환을 통해 모델링하는 기법
 - 이 과정에서 각 변환 단계는 데이터의 확률 밀도를 보존한다.
- Flow-base model의 목적 함수

$$\mathcal{L} = \mathbb{E}x \sim p_{\text{data}}(x) [\log p_{\text{model}}(x)]$$
 - $p_{\text{data}}(x)$: 실제 데이터 분포
 - $p_{\text{model}}(x)$: 모델이 학습하는 데이터의 분포

$$\log p_{\text{model}}(x) = \log p_z(f(x)) + \log \left| \det \left(\frac{\partial f(x)}{\partial x} \right) \right|$$

- $f(x)$: 데이터 x 를 간단한 분포의 공간으로 매핑하는 가역적 변환 함수
- $p_z(f(x))$: 변환된 공간에서의 간단한 분포(ex. 정규분포)
- $\left| \det \left(\frac{\partial f(x)}{\partial x} \right) \right|$: 변환의 야코비안 행렬(Jacobian matrix)의 결정자(determinant)의 절대값(입력 공간과 변환된 공간 사이의 볼륨 변화를 측정)

→ 이러한 로그 가능도를 최대화함으로써, 모델이 실제 데이터 분포를 잘 근사하도록 학습한다.

Diffusion

Diffusion 모델 : 데이터의 분포를 학습하는 대신, 데이터를 점진적으로 노이즈로 변환하는 과정과 그 역과정을 모델링한다. 이 과정은 확률론적인 방법을 사용하여 데이터를 생성하는 데 중점을 둔다.

- 핵심
 - Forward Process (전파 과정)
 - 실제 데이터 분포에서 샘플링된 데이터에 점진적으로 노이즈를 추가하는 과정
 - 이는 일련의 단계를 거쳐 이루어지며, 각 단계는 데이터에 더 많은 노이즈를 추가한다.
 - 최종적으로, 데이터는 완전한 노이즈로 변환된다.
 - Reverse Process (역과정)
 - 노이즈 데이터로부터 원본 데이터를 복원하는 과정
 - 이 과정은 학습된 모델을 사용하여 수행되며, 점진적으로 노이즈를 제거하여 최종적으로 원본 데이터와 유사한 샘플을 생성한다.

Diffusion 모델의 핵심은 두 과정(전파 과정과 역과정)을 정량화하는 것이다.

- 전파 과정

$$x_t = \sqrt{1 - \beta_t} x_{t-1} + \sqrt{\beta_t} \epsilon$$

- x_t : 시간 t 에서의 데이터
- β_t : 노이즈의 크기를 조절하는 매개변수
- ϵ : 표준 정규 분포에서 샘플링된 노이즈

- 역과정

$$x_{t-1} = f(x_t, t, \theta)$$

- x_t : 시간 t 에서의 노이즈가 추가된 데이터
- f : 신경망을 통해 학습된 함수
- θ : 신경망의 매개변수

→ x_t 와 현재 시간 t , 그리고 학습된 매개변수 θ 를 사용하여 이전 단계의 데이터 x_{t-1} 를 추정한다. 이 과정을 반복하여 최종적으로 노이즈가 제거된 원본 데이터에 가까운 샘플을 얻을 수 있다.

- Diffusion의 목적 함수

$$\mathcal{L}(\theta) = \mathbb{E}q(x_0 : T) [\log p_\theta(x_{0:T})]$$

- $q(x_{0:T})$: 데이터 x_0 에서 시작하여 노이즈를 점진적으로 추가하여 x_T 까지 도달하는 과정을 나타내는 확률분포
- $p_\theta(x_{0:T})$: 모델이 학습하는 역과정의 확률분포

→ 모델이 실제 데이터 분포와 가까운 데이터를 생성할 수 있도록 학습하는 데 사용된다.